

分類模型與電腦視覺評估指標筆記

Classification & Computer Vision Metrics | Medical Image Segmentation

目前研究方向為 **SegResNet / nnU-Net / 3D Medical Imaging**，請特別留意「四、醫學影像 Segmentation 專用指標」。

30 秒總覽（先建立地圖，再看細節）

分類指標（混淆矩陣）

- └ 排序能力: AUC
- └ 抓病人: Sensitivity
- └ 排健康: Specificity
- └ 報警準: PPV (Precision)
- └ 排除準: NPV

分割指標（Segmentation）

- └ Region 重疊得好不好? Dice / IoU
- └ Boundary 邊界準不準? HD / HD95 / ASSD / NSD
- └ Volume 體積接不接近? VS

看到論文數字時的直覺反應：

看到這個	立刻想
Dice / IoU 高	重疊得好
HD95 / ASSD 小	邊界誤差小
NSD 高	surface 落在容許範圍內的比例高

最基本組合： $Dice + HD95$ 更完整： $Dice + HD95 + ASSD/NSD$

零、混淆矩陣基礎（Confusion Matrix）

1. 表格結構

所有分類指標都是從這張 2×2 表格衍生出來的，是最基本的視覺錨點：

	預測 Positive（陽性）	預測 Negative（陰性）
實際 Positive	TP（True Positive，真陽）	FN（False Negative，假陰 / 類似 Type II Error）
實際 Negative	FP（False Positive，假陽 / 類似 Type I Error）	TN（True Negative，真陰）

判讀口訣：第一個字看對錯（True = 猜對，False = 猜錯）；第二個字看模型猜什麼（Positive = 猜正類，Negative = 猜負類）。例如 FN = 猜錯（False）+ 猜成陰性（Negative）→ 其實是陽性，但模型說是陰性，也就是「漏診」。

2. 實務觀念：門檻調校與正規化

- 分類閾值（Threshold）：**混淆矩陣的數值會隨判定門檻改變。降低門檻時（如由 0.5 降至 0.2），通常會使更多樣本被判為 Positive，因此 **TP 與 FP 傾向增加，FN 與 TN 傾向減少**（提升 Sensitivity，降低 Specificity）。
- 正規化混淆矩陣（Normalized Confusion Matrix）：**當正負樣本數量懸殊時，將矩陣轉換為比例/百分比（0.0 ~ 1.0），有助於更客觀地比較不同類別的辨識表現。

一、分類評估指標（Classification Metrics）

1. AUC（Area Under the ROC Curve）

衡量模型在不同 Threshold 下的**排序與區分能力**。

- 本質：隨機抽一個正樣本與一個負樣本，模型給正樣本較高分數的機率
- $AUC = 1.0$ 完美 $AUC = 0.5$ 等同隨機猜測 $AUC < 0.5$ 預測方向相反
- ⚠ 極度不平衡資料下，AUC 仍可能過度樂觀，需搭配 Sensitivity、PPV 一起看

2. Accuracy (準確率)

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN}$$

最直覺，但在資料極度不平衡時會失真（例如 99 個健康、1 個生病，全猜健康也有 99% Accuracy）。

3. Sensitivity (敏感度 / Recall / TPR)

$$\text{Sensitivity} = \frac{TP}{TP + FN}$$

站在「真真正類」角度：有多少真正有病的人被抓出來。

4. Specificity (特異度 / TNR)

$$\text{Specificity} = \frac{TN}{TN + FP}$$

站在「真實負類」角度：有多少真正健康的人被正確判斷為陰性。

好記口訣 — SnNout / SpPin：

- **SnNout**：Sensitivity 高的檢測，**N**egative 結果可以放心排**out**（排除疾病）
- **SpPin**：Specificity 高的檢測，**P**ositive 結果可以放心確**in**（確診疾病）

對應到情境：癌症篩檢要「寧可錯殺不可放過」→ 要高 Sensitivity (SnNout)；確診用的檢測要「報陽性就是真的有」→ 要高 Specificity (SpPin)。

5. PPV (Precision / 陽性預測值)

$$\text{PPV} = \frac{TP}{TP + FP}$$

站在「模型預測為陽性」的角度：警報有多準。受盛行率 (Prevalence) 影響很大。

6. NPV (陰性預測值)

$$\text{NPV} = \frac{TN}{TN + FN}$$

站在「模型預測為陰性」的角度：告訴你「沒問題」時，你可以有多安心。

7. F1-Score 與 Dice Coefficient

$$\text{F1} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} = \frac{2TP}{2TP + FP + FN} \quad \text{Dice} = \frac{2|P \cap G|}{|P| + |G|}$$

- **F1 的本質**：模型抓到的正類有多準 (Precision)、又抓到多少該抓的 (Recall)，這兩者的平衡好不好？用調和平均計算，所以只要有一項很低，整體分數就會被拉低。
- **F1 與 Dice 的關係**：在二元分割且以 pixel 為單位時，F1 與 Dice 數學上等價（後面「四、1」的 Dice 就是同一個東西，只是換到分割脈絡再強調一次）——但這是特殊情境下的巧合，F1 本身不是為了量「重疊」而生的
- 多類別分割通常改用 per-class Dice 再取 mean Dice

8. 其他常用指標

指標	公式	說明
FPR	$\frac{FP}{FP + TN} = 1 - \text{Specificity}$	假陽性率（誤報率），ROC 的 X 軸
FNR	$\frac{FN}{TP + FN} = 1 - \text{Sensitivity}$	假陰性率（漏報率）
MCC	$\frac{TP \times TN - FP \times FN}{\sqrt{(TP + FP)(TP + FN)(TN + FP)(TN + FN)}}$	範圍 -1 ~ +1，極度不平衡時較穩健

二、電腦視覺常見指標（Detection & Segmentation）

1. IoU（Intersection over Union / Jaccard Index）

$$\text{IoU} = \frac{|P \cap G|}{|P \cup G|} = \frac{TP}{TP + FP + FN}$$

預測區域與真實區域的重疊程度，Object Detection 與 Segmentation 都常用。

2. Dice 與 IoU 的換算

$$\text{Dice} = \frac{2 \cdot \text{IoU}}{1 + \text{IoU}} \qquad \text{IoU} = \frac{\text{Dice}}{2 - \text{Dice}}$$

Dice 永遠 $\geq$ IoU（同一個重疊程度，Dice 的數字看起來比較「好看」）。

3. PR Curve、AP、mAP

- **PR Curve**: Recall 為 X 軸、Precision 為 Y 軸；在正類稀少的情況下，通常比 ROC Curve 更能反映模型對少數類的辨識能力
- **AP**: 單一類別的 PR 曲線面積；**mAP** = 所有類別 AP 的平均

$$\text{mAP} = \frac{1}{N} \sum_{i=1}^N AP_i$$

- **AP@0.5**: IoU 門檻 = 0.5 **AP@0.5:0.95**: IoU 從 0.5 到 0.95、間隔 0.05 平均（COCO 標準）

4. PR-AUC


Precision-Recall Curve 下的面積。在**正類非常稀少**的情況下，通常比 ROC-AUC 更能反映模型對少數類的真實辨識能力。

三、錯誤類型（Type I & Type II）

錯誤	對應	意義	代價
FP（假陽性）	類似 Type I Error	沒事報有事	誤診、假警報
FN（假陰性）	類似 Type II Error	有事報沒事	漏診（通常更嚴重）

統計假設檢定的 Type I / II 與分類的 FP / FN 只是**結構相似的類比**，並非完全等價。

四、醫學影像 Segmentation 專用指標（重點）





1. Region 指標

Dice (與「一、七」同一個定義，這裡是分割脈絡下的主角)

$$\text{Dice} = \frac{2|P \cap G|}{|P| + |G|} = \frac{2TP}{2TP + FP + FN}$$

範圍 0~1，越高越好。回答：「Prediction 和 Ground Truth 重疊得有多好？」

IoU (同「二、一」)

$$\text{IoU} = \frac{|P \cap G|}{|P \cup G|}$$

一個小範例，把數字釘進腦子裡

假設某張切片標註腫瘤共 100 個 pixel (Ground Truth)，模型預測出 90 個 pixel，其中兩者重疊 80 個 pixel：

值	數字
$ P \cap G $ (重疊)	80
$ P $ (預測面積)	90
$ G $ (真實面積)	100
TP / FP / FN	80 / 10 / 20

$$\text{Dice} = \frac{2 \times 80}{90 + 100} = 0.842 \quad \text{IoU} = \frac{80}{90 + 100 - 80} = 0.727 \quad \text{Sensitivity} = \frac{80}{100} = 0.80 \quad \text{PPV} = \frac{80}{90} = 0.889$$

代入 Dice/IoU 換算式驗證： $\frac{2 \times 0.727}{1 + 0.727} = 0.842$ ✓ 對得起來。

2. Boundary 指標

Hausdorff Distance (HD)

$$h(A, B) = \max_{a \in A} \min_{b \in B} d(a, b) \quad \text{HD}(A, B) = \max \{h(A, B), h(B, A)\}$$

衡量兩個邊界「最糟糕可以差多遠」，對單一 outlier 非常敏感。

HD95 (強烈建議使用)：用表面距離分佈的 95th percentile，比原始 HD 穩定得多。回答：「大部分邊界與 Ground Truth 大約差多遠？」單位通常是 mm (讀 paper 一定要確認單位)。

ASSD / ASD (Average Symmetric Surface Distance)：平均雙向表面距離，比 HD 穩定、比 HD95 更看整體平均。

NSD (Normalized Surface Dice)：有多少比例的 surface 落在指定 tolerance (例如 2mm) 內。必須搭配 tolerance 一起解讀。

3. Volume 指標

Volumetric Similarity (VS)

$$\text{VS} = 1 - \frac{|V_P - V_G|}{V_P + V_G}$$

看預測體積與真實體積有多接近。⚠ 不同論文定義可能略有差異，讀 paper 時留意作者自訂的版本。

指標互補關係一覽

類型	指標	核心問題	趨勢
Region	Dice / IoU	重疊多少？	↑ 越好
Boundary	HD	最差邊界距離？	↓ 越好
Boundary	HD95	95% 邊界距離？	↓ 越好
Boundary	ASSD	平均邊界距離？	↓ 越好
Boundary	NSD	Surface 有多少在 tolerance 內？	↑ 越好
Volume	VS	體積有多接近？	↑ 越好

五、ROC 曲線快速理解

- **X 軸**：FPR（假陽性率）→ 越低越好
- **Y 軸**：TPR / Sensitivity → 越高越好
- 曲線越靠近左上角 (0,1) → 模型越好；對角線 → 隨機猜測

降低 Threshold 時：Sensitivity ↑、Recall ↑，但 Specificity ↓、Precision 通常下降。

六、速查表

指標	觀察角度	適用情境
AUC	排序與區分能力	跨模型比較
Accuracy	全局正確率	資料平衡時
Sensitivity	真實患者抓出率（SnNout）	醫療篩檢（不可漏）
Specificity	真實健康者辨識率（SpPin）	減少假警報
PPV (Precision)	模型警報準確度	誤報代價高時
NPV	陰性結果可靠度	排除疾病時
F1 / Dice	Precision 與 Recall 平衡	不平衡資料、分割
IoU	區域重疊程度	Detection、Segmentation
HD95	邊界品質	醫學影像分割
MCC	四個象限綜合	極度不平衡資料

七、目前研究方向最重要的組合

如果主要做 **Medical Image Segmentation / SegResNet / nnU-Net**：

$$Dice + IoU + HD95 + ASSD + NSD$$

再搭配：

$$Sensitivity + Precision + Specificity$$

就能建立一套完整且實用的評估觀念。